

Informe Técnico – Plataforma Big Data para el Análisis de Riesgo de Incendios Forestales.

Autores:

Ignacia Reyes Espinoza.

Carlo Reyes Espinoza.

Fecha: 01 de julio de 2026.

1. Introducción.....	2
2. Arquitectura general de la solución.....	4
2.1 Descripción de la arquitectura propuesta.....	4
2.2 Componentes de la arquitectura.....	5
2.3 Flujo completo del proceso.....	6
3. Fuentes de datos e ingesta de información.....	7
3.1 Descripción de las fuentes de datos.....	7
3.2 Obtención de la información de incendios forestales.....	7
3.3 Obtención de la información de postas rurales.....	8
3.4 Obtención de información meteorológica en tiempo real.....	9
3.5 Estrategia de ingesta implementada.....	10
4. Automatización de la ingesta de datos.....	11
4.1 Introducción al proceso de automatización.....	11
4.2 Almacenamiento inicial en Cloud Storage.....	11
4.3 Automatización de la carga Batch hacia BigQuery.....	12
4.4 Automatización de la consulta meteorológica.....	15
4.5 Automatización mediante Cloud Scheduler.....	16
4.6 Almacenamiento automático en BigQuery.....	17
5. Transformación de datos y construcción del Data Warehouse.....	19
5.1 Proceso ELT implementado.....	19
5.2 Limpieza y estandarización de los datos.....	19
5.3 Construcción de las dimensiones.....	20
5.4 Construcción de la tabla hechos.....	21
5.5 Resultado del Data Warehouse.....	22
6. Visualización y análisis de la información.....	22
6.1 Integración de BigQuery con Looker Studio.....	22
6.2 Diseño del Dashboard.....	23
6.3 Mapa de alertas geográficas.....	23
6.4 Distribución de alertas por región.....	23
6.5 Condiciones meteorológicas por estación.....	24
6.6 Relación entre variables meteorológicas.....	25
7. Evaluación de la solución implementada.....	27
7.1 Cumplimiento de los objetivos del proyecto.....	27
7.2 Beneficios de la arquitectura desarrollada.....	27
7.3 Posibles mejoras futuras.....	28
8. Conclusiones.....	29

1. Introducción.

La gestión de emergencias ocasionadas por incendios forestales representa uno de los principales desafíos para los organismos públicos encargados de proteger a la población y a la infraestructura crítica del país. En Chile, el aumento de este tipo de eventos durante los últimos años ha evidenciado la necesidad de contar con herramientas tecnológicas capaces de integrar información proveniente de múltiples fuentes para apoyar la toma de decisiones de manera oportuna.

En las etapas anteriores del proyecto se desarrolló una arquitectura Big Data basada en Google Cloud Platform (GCP), orientada a integrar información histórica de incendios forestales y datos geográficos correspondientes a postas rurales distribuidas a nivel nacional. Para ello se implementó un proceso de carga Batch que permite almacenar ambas fuentes de datos en Cloud Storage, procesarlas mediante BigQuery y construir un modelo dimensional capaz de identificar automáticamente las postas rurales ubicadas dentro de zonas potencialmente afectadas por incendios forestales.

El presente informe corresponde a la evolución de dicha arquitectura, incorporando una tercera fuente de información en tiempo real mediante el consumo de una API meteorológica pública. Esta integración permite complementar las alertas generadas previamente con variables climáticas relevantes para la propagación de incendios, tales como temperatura ambiente, humedad relativa, velocidad del viento y dirección predominante del viento. Estos indicadores permiten contextualizar el nivel de riesgo existente en cada zona afectada y entregar información adicional para la planificación de acciones preventivas y la protección de pacientes e infraestructura sanitaria.

Con el propósito de automatizar completamente este proceso, se implementó una arquitectura ELT (Extract, Load and Transform) utilizando diversos servicios administrados de Google Cloud Platform. La información meteorológica es consultada automáticamente cada cinco minutos mediante Cloud Scheduler, posteriormente es procesada a través de un servicio desarrollado en Python que consume la API Explorador Climático CR2 y finalmente almacena los registros en BigQuery para su posterior análisis.

Una vez consolidadas las tres fuentes de información (incendios forestales, postas rurales y condiciones meteorológicas), se amplió el modelo dimensional previamente construido incorporando una nueva dimensión correspondiente a la información climática. Este modelo facilita la construcción de consultas analíticas, el cálculo de indicadores espaciales y la generación de alertas que consideran tanto la cercanía geográfica de los incendios como las condiciones meteorológicas que podrían favorecer su propagación.

Finalmente, toda la información procesada es presentada mediante un panel desarrollado en Looker Studio, el cual permite visualizar mapas, indicadores y alertas de forma interactiva, proporcionando una herramienta de apoyo para la toma de decisiones en escenarios de emergencia.

De esta forma, la solución desarrollada demuestra cómo una arquitectura Big Data basada en servicios cloud permite integrar fuentes de datos heterogéneas, automatizar procesos de ingesta Batch y en tiempo real, construir un Data Warehouse orientado al análisis

geoespacial y generar visualizaciones que apoyan la gestión de riesgos asociados a incendios forestales.

2. Arquitectura general de la solución.

2.1 Descripción de la arquitectura propuesta.

Con el objetivo de construir una plataforma capaz de integrar información proveniente de distintas fuentes y procesarla de manera automática, se diseñó una arquitectura Big Data basada completamente en servicios administrados de Google Cloud Platform (GCP). La solución implementa un flujo ELT (Extract, Load and Transform), donde los datos son extraídos desde diferentes orígenes, almacenados inicialmente en la nube, posteriormente transformados mediante herramientas de procesamiento y finalmente consolidados en un Data Warehouse para su análisis y visualización.

La arquitectura considera tanto procesos Batch como procesos en tiempo real. Los datos históricos de incendios forestales y la infraestructura de salud rural son procesados mediante cargas Batch, mientras que la información meteorológica es obtenida automáticamente cada cinco minutos desde una API pública, permitiendo complementar las alertas existentes con condiciones climáticas actualizadas.

Esta integración de diferentes mecanismos de ingesta permite disponer de información histórica y datos en tiempo real dentro de una misma plataforma analítica, facilitando la generación de indicadores y apoyando la toma de decisiones frente a posibles emergencias.




Figura 1. Arquitectura general del flujo ELT implementado en Google Cloud Platform.

2.2 Componentes de la arquitectura.

La solución desarrollada se encuentra dividida en cuatro grandes etapas, cada una encargada de una función específica dentro del procesamiento de datos.

Origen de los datos:

La primera etapa corresponde a las fuentes de información utilizadas durante el proyecto. Se trabajó con tres orígenes de datos distintos:

- Incendios forestales históricos, obtenidos mediante archivos CSV.
- Postas rurales, obtenidas desde una API REST pública del Geoportal de Chile.
- Información meteorológica, consultada periódicamente desde la API Explorador Climático CR2.

Cada una de estas fuentes entrega información complementaria que, una vez integrada, permite determinar qué establecimientos de salud podrían verse afectados por incendios forestales y cuáles son las condiciones climáticas presentes en su entorno.

Proceso:

En la segunda etapa se implementaron los procesos encargados de automatizar la adquisición y transformación de la información.

Los archivos provenientes de las fuentes Batch son almacenados inicialmente en Cloud Storage como un Data Lake temporal, desde donde posteriormente son cargados hacia BigQuery mediante procesos desarrollados en Python utilizando la librería oficial de Google Cloud.

Por otra parte, la información meteorológica es consultada automáticamente cada cinco minutos mediante Cloud Scheduler. El servicio ejecuta un programa desarrollado en Python que consume la API meteorológica, procesa información recibida y finalmente almacena los registros en BigQuery.

Durante esta etapa también se realizan tareas de limpieza, normalización y estandarización de los datos, garantizando la consistencia del modelo analítico.

Almacén de datos:

La tercera etapa corresponde al almacenamiento definitivo de la información.

Para ello se implementó un Data Warehouse sobre BigQuery, aprovechando sus capacidades de procesamiento distribuido y funciones geoespaciales.

Sobre este repositorio se construyó un modelo dimensional compuesto por una tabla central de hechos (alertas) y las dimensiones correspondientes a:

- Incendios.
- Postas rurales.
- Tiempo.
- Territorio.
- Meteorología.

Consumo de información:

Finalmente, la información almacenada en BigQuery es consumida mediante Data Studio.

En esta herramienta se desarrolló un dashboard interactivo que permite visualizar:

- Distribución geográfica de incendios.
- Ubicación de postas rurales.
- Alertas críticas.
- Condiciones meteorológicas asociadas.
- Indicaciones de riesgo.

De esta forma, la solución entrega una plataforma de análisis visual que facilita la interpretación de la información por parte de los usuarios finales.

2.3 Flujo completo del proceso.

El flujo implementado durante el proyecto puede resumirse de la siguiente manera:

1. Obtención de información desde archivos CSV, API de postas rurales y API meteorológica.
2. Almacenamiento inicial de los datos en CCloud Storage.
3. Procesamiento de la ingesta en tiempo real utilizando Cloud Scheduler.
4. Almacenamiento definitivo en BigQuery.
5. Construcción del modelo dimensional.
6. Publicación de indicadores y paneles interactivos en Data Studio.

Este flujo permite que la mayor parte del proyecto opere de manera automática, reduciendo la intervención manual y asegurando la actualización continua de la información disponible para el análisis.

3. Fuentes de datos e ingesta de información.

3.1 Descripción de las fuentes de datos.

El desarrollo del proyecto requirió integrar información proveniente de distintas fuentes con características y formatos diferentes. Para ello se seleccionaron tres conjuntos de datos que, al ser combinados, permiten evaluar el riesgo que enfrentan las postas rurales cercanas a incendios forestales y complementar dicho análisis con información meteorológica actualizada.

Las fuentes utilizadas corresponden a información histórica de incendios forestales, establecimientos de salud rural y datos meteorológicos obtenidos mediante una API pública. Cada una de ellas posee una frecuencia de actualización distinta, por lo que fue necesario implementar estrategias de ingesta diferenciadas para responder a sus características.

Fuente de datos	Origen	Formato	Tipo de carga
Incendios forestales	incendio	CSV	Batch
Postas rurales	posta	API otorgada / datos georreferenciados	Batch
Meteorología	API Explorador Climático CR2	JSON	Tiempo real

3.2 Obtención de la información de incendios forestales.

La primera fuente utilizada corresponde al registro histórico de incendios forestales ocurrido en Chile durante los años 2024 y 2025. Esta información fue obtenida en formato CSV y posteriormente almacenada dentro de un bucket de Google Cloud Storage para su posterior procesamiento.

El conjunto de datos contiene información geográfica y operacional de cada incendio, incluyendo su comuna, región, fecha de inicio, fecha de término, superficie afectada, temperatura máxima registrada, humedad ambiental, velocidad del viento, tipo de suelo y causas probables del incendio. Estos atributos constituyen la base para realizar análisis espaciales e identificar la proximidad entre incendios y establecimientos de salud.

Al tratarse de información histórica, su carga se realizó mediante un proceso Batch, permitiendo importar el archivo completo hacia BigQuery sin requerir consultas continuas a servicios externos.

3.4 Obtención de información meteorológica en tiempo real.

La tercera fuente incorporada durante esta entrega corresponde a información meteorológica obtenida desde la API pública Explorador Climático CR2, la cual entrega variables climáticas actualizadas para cualquier ubicación geográfica mediante consultas REST.

A diferencia de las fuentes anteriores, esta información no se almacena previamente en archivos, sino que es consultada dinámicamente durante la ejecución del sistema. Para ello se desarrolló un proceso automatizado en Python que realiza solicitudes periódicas a la API utilizando las coordenadas geográficas de las postas rurales que presentan alertas críticas.

Cada consulta devuelve información relevante para el análisis del comportamiento de los incendios forestales, entre la que se incluyen variables como temperatura del aire, precipitación, humedad relativa, velocidad del viento, dirección del viento y humedad superficial del suelo.

La incorporación de estas variables permite enriquecer el análisis espacial realizado previamente, entregando una visión más completa de las condiciones ambientales presentes en las zonas de riesgo.




Figura 4: Creación Cloud run de meteorología por medio de Cloud run.

3.5 Estrategia de ingesta implementada.

Debido a las diferencias existentes entre las fuentes de información utilizadas, fue necesario implementar dos mecanismos de ingesta distintos.

Las fuentes correspondientes a incendios forestales y postas rurales fueron tratadas mediante procesos Batch, ya que corresponden a conjuntos de datos que pueden almacenarse previamente y cargarse de forma periódica hacia BigQuery.

Por el contrario, la información meteorológica requiere reflejar las condiciones actuales del entorno, por lo que se implementó un proceso de ingesta en tiempo real basado en Cloud Scheduler y consultas dinámicas a la API Explorador Climático CR2.

Esta combinación permitió construir una arquitectura híbrida capaz de integrar información histórica y datos actualizados dentro de un mismo Data Warehouse, manteniendo un equilibrio entre rendimiento, automatización y disponibilidad de la información.

4. Automatización de la ingesta de datos.

4.1 Introducción al proceso de automatización.

Uno de los principales objetivos de esta tercera entrega consistió en transformar la solución desarrollada durante las etapas anteriores en un proceso completamente automatizado, eliminando la necesidad de ejecutar manualmente las distintas etapas de carga y procesamiento de la información.

Para lograr este objetivo se diseñó una arquitectura basada en servicios administrados de Google Cloud Platform (GCP), permitiendo que la obtención, almacenamiento, procesamiento y actualización de los datos se ejecuten de manera automática según el tipo de fuente de información utilizada.

En esta implementación se diferencian claramente dos tipos de procesos de ingesta:

- Procesos Batch, utilizados para los conjuntos de datos históricos correspondientes a incendios forestales y postas rurales.
- Procesos en tiempo real, utilizados para la obtención de información meteorológica mediante consultas periódicas a una API pública.

Esta estrategia permitió combinar información histórica con datos actualizados continuamente, manteniendo un flujo ELT automatizado y escalable.

4.2 Almacenamiento inicial en Cloud Storage.

La primera etapa del flujo automatizado consiste en almacenar las fuentes de datos Batch dentro de Google Cloud Storage. Este servicio fue utilizado como Data Lake inicial, permitiendo centralizar la información antes de su procesamiento en BigQuery.

Con el propósito de mantener una organización clara de la información, se creó un bucket independiente para cada una de las fuentes de datos utilizadas durante el proyecto:

- Bucket para incendios forestales históricos.
- Bucket para postas rurales obtenidas desde la API del Geoportal.

Esta separación facilita el mantenimiento de la arquitectura, permite controlar versiones de los archivos y simplifica futuras actualizaciones de los conjuntos de datos.

Al almacenar los archivos en Cloud Storage, el proceso de carga posterior puede ejecutarse automáticamente utilizando únicamente la dirección URL del archivo, sin necesidad de descargarlo o manipularlo manualmente.

```

# Configurar proyecto
gcloud config set project summer-surfer-443019-e0

# Crear bucket de incendios
gcloud storage buckets create gs://incendios-csv-summer-surfer-443019-e0 \
  --location=US \
  --uniform-bucket-level-access

# Crear bucket de postas
gcloud storage buckets create gs://postas-api-summer-surfer-443019-e0 \
  --location=US \
  --uniform-bucket-level-access

# Subir archivos
gcloud storage cp incendios_chile_2024_2025.csv gs://incendios-csv-summer-surfer-443019-e0/
gcloud storage cp postas_raw.json gs://postas-api-summer-surfer-443019-e0/

```

Figura 6: Buckets utilizados para almacenar el archivo histórico de incendios forestales y el archivo generado desde API postas.

4.3 Automatización de la carga Batch hacia BigQuery.

Una vez almacenados los archivos dentro de Cloud Storage, se desarrolló un proceso automatizado utilizando Python encargado de realizar la carga de los datos directamente hacia BigQuery.

El proceso fue diseñado para ejecutarse sin intervención manual, leyendo cada archivo desde su ubicación en Cloud Storage y creando o actualizando automáticamente las tablas correspondientes dentro del Data Warehouse.

Durante la implementación se configuraron distintas opciones de carga con el propósito de hacer el proceso más robusto y reutilizable. Entre las principales configuraciones implementadas destacan:

- Detección automática del tipo de datos (autodetect).
- Omisión de la fila de encabezados.
- Configuración del delimitador correspondiente a cada archivo.
- Reemplazo automático de las tablas existentes mediante WRITE_TRUNCATE.

Estas configuraciones permitieron resolver problemas detectados durante las primeras etapas del proyecto, principalmente relacionados con caracteres especiales, tildes y diferencias en la codificación de los archivos CSV.

Como resultado, el proceso puede ejecutarse múltiples veces sin generar inconsistencias en la estructura de las tablas.

```
CLOUD SHELL
Terminal (qwiklabs-gcp-00-143383fab3b5) x + ▾
Open Editor

i Gemini CLI is available in Cloud Shell terminal! Type gemini to try it. Learn more

student_00_764bc8e68e2a@cloudshell:~ (qwiklabs-gcp-00-143383fab3b5) $ BUCKET_POSTAS="consumo-api"

gcloud config set project $PROJECT_ID

echo "Proyecto activo: $PROJECT_ID"
echo "Bucket de postas: gs://$BUCKET_POSTAS"

# Crear bucket para almacenar datos obtenidos desde la API de postas
gcloud storage buckets describe gs://$BUCKET_POSTAS >/dev/null 2>&1 || \
gcloud storage buckets create gs://$BUCKET_POSTAS \
--location=US \
--uniform-bucket-level-access

# Instalar librerías necesarias
pip install requests pandas -q

# Crear script Python para consumir la API y generar el CSV
cat > obtener_postas_api.py <<'PYTHON'
import requests
import pandas as pd

def obtener_todas_las_postas_chile():
    url = "https://geoportal.cl/geoserver/EstablecimientosdesaluddeChile2025/wfs"

    params = {
        "service": "WFS",
        "version": "2.0.0",
        "request": "GetFeature",
        "typeName": "EstablecimientosdesaluddeChile2025:establecimientos_de_salud_diciembre_2025",
        "outputFormat": "application/json",
    }

    try:
        print("Descargando establecimientos de salud desde la API...")
        response = requests.get(url, params=params)
        response.raise_for_status()
        data = response.json()

        establecimientos_raw = data["features"]
        lista_establecimientos = []

        for h in establecimientos_raw:
            info = h["properties"]
            info["longitud"] = h["geometry"]["coordinates"][0]
            info["latitud"] = h["geometry"]["coordinates"][1]
            lista_establecimientos.append(info)

        df = pd.DataFrame(lista_establecimientos)
        echo "Proceso API postas finalizado."/torages://$BUCKET_POSTAS/vo}")tf-8")acional.")
```

Figura 7: Carga de las postas a BigQuery.

Query results								
Job information Results Visualization JSON Execution details Execution graph								
Row	Id_posta_ak	nombre_posta	tipo_posta	comuna	latitud	longitud	ubicacion_geo	
1	ed7f709-11a7-4ca6-8a98-b395...	POSTA DE SALUD RURAL EL YECO	POSTA DE SALUD RURAL (PSR)	ALGARROBO	-33.30806	-71.64341	POINT(-71.64341 -33.30806)	
2	012d83a0-d4aa-4b32-a547-704...	POSTA DE SALUD RURAL SAN JOSE (ALGARROBO)	POSTA DE SALUD RURAL (PSR)	ALGARROBO	-33.30198	-71.55914	POINT(-71.55914 -33.30198)	
3	95302b79-abce-4f03-adf4-8bc4...	POSTA DE SALUD RURAL EL ASIENITO	POSTA DE SALUD RURAL (PSR)	ALHUE	-34.03232	-71.00262	POINT(-71.00262 -34.03232)	
4	d6a303b6-87c5-4910-8358-1e0...	POSTA DE SALUD RURAL PICHIC	POSTA DE SALUD RURAL (PSR)	ALHUE	-33.98443	-71.06306	POINT(-71.06306 -33.98443)	
5	ca1c92ec-d728-4bdb-ac8f-ab0d...	POSTA DE SALUD RURAL CALLAQUI	POSTA DE SALUD RURAL (PSR)	ALTO BIOBIO	-37.85576	-71.67115	POINT(-71.67115 -37.85576)	
6	21ab03e7-327c-4960-8454-c89...	POSTA DE SALUD RURAL MALLA MALLA	POSTA DE SALUD RURAL (PSR)	ALTO BIOBIO	-37.71095	-71.34136	POINT(-71.34136 -37.71095)	
7	2ab3a37f-d3fa-4f98-9d11-6be2...	POSTA DE SALUD RURAL CAUÑICU	POSTA DE SALUD RURAL (PSR)	ALTO BIOBIO	-37.71329	-71.48377	POINT(-71.48377 -37.71329)	
8	e94eb31a-b4cd-4f73-81e8-d9fe...	POSTA DE SALUD RURAL TRAPA TRAPA	POSTA DE SALUD RURAL (PSR)	ALTO BIOBIO	-37.71043	-71.26598	POINT(-71.26598 -37.71043)	
9	e142bc64-96c8-4920-91e9-3dc...	POSTA DE SALUD RURAL PITRIL	POSTA DE SALUD RURAL (PSR)	ALTO BIOBIO	-37.81947	-71.55706	POINT(-71.55706 -37.81947)	

Figura 8: Visualización en BigQuery.

```
CLOUD SHELL
Terminal (qwiklabs-gcp-00-143383fab3b5) x + v Open Editor

Gemini CLI is available in Cloud Shell terminal! Type gemini to try it. Learn more Don't show again

try:
student_00_764bc8e68e2a@cloudshell:~ (qwiklabs-gcp-00-143383fab3b5)$ from google.cloud import bigqueryPROJECT_ID = "qwiklabs-gcp-03-fea74eca50b4"
DATASET_ID = f"{PROJECT_ID}.datos_emergencia"

def cargar_csv_a_bigquery(uri_bucket, nombre_tabla, delimitador):
    """Función para cargar datos Batch desde GCS a BigQuery con delimitador dinámico."""

    # Iniciamos el cliente de BigQuery
    client = bigquery.Client(project=PROJECT_ID)
    table_id = f"{DATASET_ID}.{nombre_tabla}"

    # Configuramos el proceso de carga
    job_config = bigquery.LoadJobConfig(
        source_format=bigquery.SourceFormat.CSV,
        skip_leading_rows=1, # Nos saltamos la fila de encabezados
        autodetect=True, # Detecta el tipo de dato automáticamente

        # SOLUCIÓN 1: Le pasamos el separador correcto (coma o punto y coma)
        field_delimiter=delimitador,

        # CONTROL DE DUPLICIDAD: Si la tabla ya existe, la sobrescribe
        write_disposition=bigquery.WriteDisposition.WRITE_TRUNCATE,
    )

    # SOLUCIÓN 2: Magia para limpiar columnas con tildes, símbolos o espacios (ej. "Plantación")
    job_config.column_name_character_map = "V2"

    print(f"Iniciando carga Batch desde {uri_bucket} hacia {table_id}...")

    # CONTROL DE ERRORES (Try-Except)
    try:
        # Ejecutamos el trabajo de carga (Job)
        load_job = client.load_table_from_uri(
            uri_bucket, table_id, job_config=job_config
        )

        # Esperamos a que termine el proceso
        load_job.result()

        # Validamos cuántas filas se cargaron para confirmar
        destination_table = client.get_table(table_id)
        print(f"Éxito! Se cargaron {destination_table.num_rows} filas en la tabla {nombre_tabla}.\n")

    except Exception as e:
        # Si algo falla (ej. permisos o archivo no encontrado), el código no "explota", te avisa.
        print(f"ERROR CRÍTICO en la carga de {nombre_tabla}: {str(e)}\n")

if __name__ == "__main__":
    print("--- INICIANDO PROCESO BATCH DE CARGA A BIGQUERY ---\n")
```

Figura 9: Carga de los incendios a BigQuery.

Query results

ChatSave resultsOpen in

Job Information		Results	Visualization	JSON	Execution details		Execution graph		
Row	id_incendio	inicio_incendio	termino_incendio	region	comuna	poligono_afectado	temp_max	viento_kmh	
1	INC-2024-001	2025-03-06 00:00:00 UTC	null	O'HIGGINS	Comuna_14	[(-36.6607,-70.7906),(-36.5607...	266	178	
2	INC-2024-002	2025-02-09 00:00:00 UTC	2025-02-10 07:21:58 UTC	MAULE	Comuna_5	[(-32.7842,-70.7236),(-32.7742...	267	259	
3	INC-2024-003	2025-03-12 00:00:00 UTC	2025-03-13 15:32:09 UTC	ARAUCANIA	Comuna_3	[(-34.6878,-70.5118),(-34.6778...	381	592	
4	INC-2024-004	2025-04-16 00:00:00 UTC	2025-04-17 03:32:17 UTC	O'HIGGINS	Comuna_18	[(-36.3981,-70.1900),(-36.3881...	329	198	
5	INC-2024-005	2025-02-05 00:00:00 UTC	2025-02-07 08:19:11 UTC	O'HIGGINS	Comuna_11	[(-36.1073,-72.1968),(-36.0973...	317	553	
6	INC-2024-006	2025-02-05 00:00:00 UTC	2025-02-05 20:23:30 UTC	O'HIGGINS	Comuna_2	[(-35.6036,-72.3420),(-35.5936...	357	486	
7	INC-2024-007	2025-04-19 00:00:00 UTC	2025-04-20 15:02:16 UTC	O'HIGGINS	Comuna_11	[(-37.9311,-70.8378),(-37.9211...	324	30	
8	INC-2024-008	2025-03-17 00:00:00 UTC	2025-03-18 13:32:15 UTC	ARAUCANIA	Comuna_18	[(-32.9500,-71.4770),(-32.9400...	352	319	
9	INC-2024-009	2025-01-27 00:00:00 UTC	2025-01-28 17:42:53 UTC	BIOBIO	Comuna_16	[(-33.1039,-70.0660),(-33.0939...	295	null	

Results per page: 501 - 50 of 500

Figura 10: Visualización en BigQuery.

4.4 Automatización de la consulta meteorológica.

La incorporación de información meteorológica representa la principal mejora desarrollada durante esta tercera entrega.


A diferencia de las fuentes Batch, la información climática requiere mantenerse constantemente actualizada, debido a que las condiciones ambientales cambian continuamente y pueden modificar el comportamiento de un incendio forestal.

Por este motivo se decidió implementar un proceso completamente automatizado capaz de consultar la API Explorador Climático CR2 cada cinco minutos.

El proceso desarrollado realiza las siguientes actividades:

1. Obtiene las coordenadas geográficas de las postas críticas.
2. Construye automáticamente la URL de consulta hacia la API.
3. Recibe la respuesta en formato JSON.
4. Construye un nuevo mensaje estructurado para su posterior procesamiento.

Este procedimiento permite incorporar información climática actualizada sin intervención del usuario.



Row	fecha_hora_api	fecha_hora_ingesta	comuna	latitud	longitud	temperatura_c
1	2026-06-21 01:00:00 UTC	2026-06-21 01:03:04 UTC	Arica	-18.4746	-70.2979	17.0
2	2026-06-21 01:00:00 UTC	2026-06-21 01:03:04 UTC	Iquique	-20.2133	-70.1503	15.6
3	2026-06-21 01:00:00 UTC	2026-06-21 01:03:04 UTC	Antofagasta	-23.6524	-70.3954	15.9
4	2026-06-21 01:00:00 UTC	2026-06-21 01:03:04 UTC	Copiapó	-27.3665	-70.3323	11.2
5	2026-06-21 01:00:00 UTC	2026-06-21 01:03:04 UTC	La Serena	-29.9045	-71.2489	10.4
6	2026-06-21 01:00:00 UTC	2026-06-21 01:03:04 UTC	Valparaíso	-33.0458	-71.6197	10.1
7	2026-06-21 01:00:00 UTC	2026-06-21 01:03:04 UTC	Santiago	-33.4569	-70.6483	8.6

Figura 5: Ingesta para corroborar la cloud run de datos meteorológicos.

4.5 Automatización mediante Cloud Scheduler.

Con el objetivo de evitar la ejecución manual del script meteorológico, se incorporó el servicio Cloud Scheduler.

Este servicio permite programar tareas automáticas mediante expresiones Cron, ejecutando periódicamente un proceso sin intervención humana.

Para el desarrollo del proyecto se configuró una ejecución cada cinco minutos, frecuencia suficiente para simular un monitoreo continuo de las condiciones meteorológicas alrededor de las postas rurales con nivel de alerta crítico.

Cada ejecución del Scheduler inicia automáticamente el proceso encargado de consultar la API meteorológica y generar un nuevo evento.

Esta configuración convierte la arquitectura en un sistema capaz de actualizar información continuamente, cumpliendo uno de los principales requisitos establecidos para esta entrega.




Figura 11: Creación de Schedule.




Figura 12: Visualización de Schedule.

4.6 Almacenamiento automático en BigQuery.

Finalmente, el Jobs configurado inserta automáticamente cada evento recibido dentro de la tabla “clima” del data set.

Esta tabla constituye la capa de datos correspondiente a la información meteorológica y almacena cada consulta realizada a la API, incluyendo la fecha de ejecución, fecha y hora de la ingesta, la comuna, la latitud, la longitud, la temperatura, entre otros datos.

Gracias a esta arquitectura, la actualización de la información ocurre de forma completamente automática, eliminando la necesidad de importar archivos o ejecutar procesos manuales cada vez que se desea incorporar nuevos datos.

La tabla generada sirve posteriormente como fuente para los procesos de transformación realizados en BigQuery y para la integración con el modelo dimensional desarrollado en el proyecto.

21 de jun 01:13

Jobs - Cloud Scheduler | Metrics - ... | clima_historico - | incendios_csv | meteorologia-365 | postas-36549926 | incendios-365499 | +

console.cloud.google.com/bigquery?referrer=search&project=qwiklabs-gcp-04-586e12a807cf&ws=11m1211m514m31...

Google Cloud | qwiklabs-gcp-04-586e12a807cf | big

Untitled query | Run | Save | Schedule | Share

Query completed

Query results | Chat | Save results | Open in

Job information	Results	Visualization	JSON	Execution details	Execution graph			
Row	fecha_hora_api	fecha_hora_ingesta	comuna	latitud	longitud	temperatura_c	precipitacion_mm	viento_kmh
46	2026-06-21 01:00:00 UTC	2026-06-21 01:11:35 UTC	Puerto Montt	-41.4693	-72.9424	5.8	0.1	
47	2026-06-21 01:00:00 UTC	2026-06-21 01:11:35 UTC	Coyhaique	-45.5712	-72.0683	2.9	0.0	
48	2026-06-21 01:00:00 UTC	2026-06-21 01:11:35 UTC	Punta Arenas	-53.1548	-70.9113	3.6	0.0	
49	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	Arica	-18.4746	-70.2979	17.0	0.0	
50	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	Iquique	-20.2133	-70.1503	15.6	0.0	
51	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	Antofagasta	-23.6524	-70.3954	15.9	0.0	
52	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	Copiapó	-27.3665	-70.3323	11.2	0.0	
53	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	La Serena	-29.9045	-71.2489	10.4	0.0	
54	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	Valparaíso	-33.0458	-71.6197	10.1	0.0	
55	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	Santiago	-33.4569	-70.6483	8.6	0.0	
56	2026-06-21 01:00:00 UTC	2026-06-21 01:12:02 UTC	Rancagua	-34.1708	-70.7445	5.7	0.0	

Results per page: 200 | 1 - 64 of 64 | < > >>

Figura 13: Verificación de funcionamiento del Schedule.

5. Transformación de datos y construcción del Data Warehouse.

5.1 Proceso ELT implementado.

Una vez finalizados los procesos de ingesta Batch y en tiempo real, toda la información obtenida desde las distintas fuentes queda almacenada inicialmente en BigQuery. A diferencia de un proceso ETL tradicional, donde las transformaciones se realizan antes del almacenamiento, en este proyecto se implementó una arquitectura ELT (Extract, Load and Transform).

En este enfoque, los datos son extraídos desde las fuentes originales y cargados directamente en BigQuery, manteniendo inicialmente su estructura original. Posteriormente, utilizando consultas SQL y las capacidades de procesamiento del motor analítico de BigQuery, se realizan todas las transformaciones necesarias para preparar la información que será utilizada en el análisis y la visualización.

La elección de un proceso ELT permitió aprovechar el procesamiento distribuido de BigQuery, reduciendo la complejidad de los procesos externos y facilitando la incorporación de nuevas transformaciones sin necesidad de volver a cargar la información desde las fuentes originales.

5.2 Limpieza y estandarización de los datos.

Durante las primeras pruebas del proyecto se identificaron diversas inconsistencias en los datos provenientes de las distintas fuentes, principalmente relacionadas con diferencias de formato, caracteres especiales y codificación de texto.

Entre las principales tareas de limpieza realizadas se encuentran:

- Normalización de nombres de regiones y comunas.
- Eliminación de caracteres especiales y tildes.
- Conversión de texto a minúsculas para facilitar las comparaciones.
- Estandarización de coordenadas geográficas.
- Corrección de tipos de datos detectados automáticamente por BigQuery.
- Eliminación de registros incompletos o inconsistentes.

Estas transformaciones permitieron unificar el formato de los datos provenientes de distintas fuentes, facilitando posteriormente la creación de relaciones entre tablas y el uso de funciones geoespaciales.

5.3 Construcción de las dimensiones.

Una vez normalizados los datos, se inició la construcción del modelo dimensional que serviría como base para el Data Warehouse.

Cada dimensión fue diseñada con el propósito de almacenar información descriptiva sobre una entidad específica, evitando redundancias y facilitando la construcción de consultas analíticas.

Dimensión Incendios.

La dimensión dim_incendios almacena la información principal asociada a cada incendio forestal registrado.

Entre sus principales atributos se encuentran:

- id_incendio.
- region.
- comuna.
- fecha_inicio.
- fecha_termino.
- superficie_ha.
- peligro_interfazl.
- estado_validacion.
- tipo_suelo.
- causa_probable.
- es_activo.

Dimensión Postas.

La dimensión dim_postas almacena la información correspondiente a las postas rurales obtenidas desde la API del Geoportal.

En ella se incluyen atributos como:

- id_posta.
- nombre_posta.
- region.
- comuna.
- latitud.
- longitud.
- geom.
- EstadoFuncionamiento.
- FechaCierre.
- FechaIncorporacion.
- esta_activa.

Dimensión Clima.

Como principal incorporación de esta tercera entrega, se desarrolló la dimensión dim_meteorologia, encargada de almacenar las condiciones climáticas obtenidas desde la API meteorológica.

Esta dimensión incorpora variables que complementan el análisis de riesgo, entre ellas:

- estacion.
- fecha_hora_api.
- latitud.
- longitud.
- geom.
- temperatura_c.
- precipitacion_mm.
- viento_kmh.
- humedad_pct.
- codigo_clima.

5.4 Construcción de la tabla hechos.

Una vez creadas las dimensiones, se desarrolló la tabla central del Data Warehouse denominada vw_alerta_posta.

Esta tabla integra la información proveniente de incendios, postas rurales y meteorología, almacenando únicamente los identificadores de las dimensiones y las métricas necesarias para el análisis.

Entre las principales medidas registradas se encuentran:

- id_posta.
- nombre_posta.
- region_posta.
- comuna_posta.
- lat_posta.
- lon_posta.
- id_incendio.
- region_incendio.
- nivel_alerta.
- tipo_suelo.
- superficie_ha.
- estacion_clima_cercana.
- temperatura_c.
- humedad_pct.
- viento_kmh.
- viento_fuerte.
- riesgo_propagacion.

5.5 Resultado del Data Warehouse.

Como resultado del proceso ELT implementado, se obtuvo un Data Warehouse centralizado en BigQuery, compuesto por una tabla de hechos y un conjunto de dimensiones que integran información histórica, geográfica y meteorológica.

Este modelo facilita la ejecución de consultas analíticas complejas, mejora el rendimiento de las visualizaciones y constituye la base para la construcción del dashboard desarrollado en Looker Studio.

Además, la incorporación de la dimensión meteorológica representa una mejora significativa respecto de la entrega anterior, permitiendo complementar el análisis espacial con variables ambientales obtenidas en tiempo real.

6. Visualización y análisis de la información.

6.1 Integración de BigQuery con Looker Studio.

Una vez finalizados los procesos de ingesta, transformación y modelamiento de los datos, se integró BigQuery con Google Data Studio para desarrollar un panel de control que permitiera visualizar de manera interactiva toda la información generada por la solución Big Data.

Data Studio fue seleccionado debido a su integración nativa con BigQuery, permitiendo consultar directamente las tablas del Data Warehouse sin necesidad de exportar información hacia otras herramientas. Gracias a esta integración, cada actualización realizada sobre las tablas de BigQuery puede ser visualizada automáticamente dentro del dashboard, manteniendo la información disponible para el análisis de manera prácticamente inmediata.

El panel fue construido utilizando como fuente las vistas creadas para utilizar en Data Studio, las cuales son vw_alerta_posta, vw_riesgo_climatico y dim_incendio, las cuales integran información proveniente de las dimensiones de incendios, postas rurales y meteorología, consolidando todos los indicadores necesarios para el análisis.



Nombre	Tipo de conector	Tipo	Se usa en el informe	Estado	Acciones
 vw_riesgo_climatico	BigQuery	 Insertada	2 gráficos, 0 variables	Activa	 EDITAR  DUPLICAR  ELIM
 vw_alerta_posta	BigQuery	 Reutilizable	7 gráficos, 0 variables	Activa	 EDITAR  DUPLICAR  ELIM
 dim_incendio	BigQuery	 Insertada	2 gráficos, 0 variables	Activa	 EDITAR  DUPLICAR  ELIM

Figura 14: Conexión entre BigQuery y Data Studio.

6.2 Diseño del Dashboard.

El dashboard fue diseñado con el propósito de entregar una visión integral del comportamiento de los incendios forestales respecto a la infraestructura crítica de salud rural.

Se buscó presentar la información mediante diferentes tipos de visualización, permitiendo interpretar rápidamente el estado de las alertas, identificar las zonas de mayor riesgo y conocer las condiciones meteorológicas asociadas a cada posta rural.

El panel combina indicadores geográficos, gráficos estadísticos y tablas detalladas, facilitando la exploración de la información sin necesidad de ejecutar consultas SQL directamente sobre BigQuery.

6.3 Mapa de alertas geográficas.

Uno de los principales componentes del dashboard corresponde al mapa interactivo, el cual representa geográficamente las postas rurales utilizando sus coordenadas de latitud y longitud almacenadas en BigQuery.

Cada punto del mapa corresponde a una posta rural y utiliza una escala de colores basada en el nivel de riesgo de propagación del incendio. Además, el tamaño de cada marcador se encuentra asociado a la velocidad del viento registrada por la API meteorológica, permitiendo identificar rápidamente aquellas zonas donde las condiciones climáticas podrían favorecer la propagación del fuego.

Al seleccionar una posta sobre el mapa, el usuario puede visualizar información adicional como temperatura, ubicación y nivel de riesgo.

6.4 Distribución de alertas por región.

Con el objetivo de identificar las zonas más afectadas, se implementó un gráfico de barras apiladas denominado "Alertas por Región y Nivel de Riesgo".

Este gráfico permite comparar la cantidad de alertas existentes en cada región del país, clasificándolas según su nivel de riesgo (bajo, medio, alto o crítico). De esta manera, resulta posible identificar rápidamente aquellas regiones que concentran un mayor número de establecimientos expuestos a incendios forestales.

Esta visualización constituye un apoyo importante para la priorización de recursos durante una emergencia.

Alertas por Región y Nivel de Riesgo




Figura 15: Alertas por región y nivel de riesgo.

6.5 Condiciones meteorológicas por estación.

Una de las principales mejoras incorporadas durante esta tercera entrega corresponde a la integración de información meteorológica obtenida desde la API Open-Meteo.

El dashboard incorpora una tabla donde se presentan las condiciones climáticas registradas para cada estación consultada, incluyendo variables tales como:

- temperatura.
- humedad relativa.
- velocidad del viento.
- dirección del viento.
- nivel estimado de riesgo de propagación.

Además, con el fin de resumir el comportamiento general de las variables climáticas, el dashboard incorpora gráficos estadísticos que representan la distribución de temperatura, humedad y velocidad del viento obtenidas desde la API meteorológica.

Estos indicadores permiten identificar rápidamente las condiciones ambientales predominantes durante el momento de la consulta, proporcionando una visión general del escenario meteorológico asociado a las alertas.

Condiciones Climáticas Actuales por Estación

	estacion +	temperatura_c	humedad_pct	viento_kmh	riesgo_propagacion
1.	Antofagasta	15,73	90,77	2,88	1
2.	Arica	17,08	75	0,88	1
3.	Chillan	5,1	97,19	8	1
4.	Concepcion	8,12	89,73	6,37	1
5.	Coplapo	11,18	90,04	2,38	1
6.	Coyhaique	2,8	91	1,5	1
7.	Iquique	15,5	91,77	1,05	1

1 - 10 / 10 < >




Figura 16: *Tabla de condiciones meteorológicas e indicadores climáticos.*

6.6 Relación entre variables meteorológicas

Como complemento del análisis, se desarrolló un gráfico de dispersión que representa la relación existente entre temperatura, humedad, velocidad del viento y riesgo de propagación.

Cada punto representa una estación meteorológica asociada a una posta rural, permitiendo observar visualmente cómo las condiciones climáticas influyen sobre el nivel de riesgo estimado.

Esta representación facilita la identificación de patrones y constituye un apoyo para el análisis exploratorio de los datos.

Condiciones Climáticas por Estación: Temperatura, Humedad y Viento




Figura 17: Alertas por región y nivel de riesgo.

7. Evaluación de la solución implementada.

7.1 Cumplimiento de los objetivos del proyecto.

El desarrollo del proyecto permitió implementar una arquitectura Big Data completamente funcional utilizando servicios de Google Cloud Platform para la integración, almacenamiento, procesamiento y visualización de datos provenientes de distintas fuentes de información.

La solución construida logró automatizar el flujo de datos desde la obtención de la información hasta su representación en un panel analítico, reduciendo la intervención manual y permitiendo mantener actualizada la información utilizada para el monitoreo de incendios forestales cercanos a infraestructura crítica de salud.

Asimismo, la incorporación de información meteorológica en tiempo real permitió enriquecer el análisis de riesgo, proporcionando variables adicionales que pueden influir directamente en la propagación de un incendio forestal y, por lo tanto, en la toma de decisiones frente a una emergencia.

7.2 Beneficios de la arquitectura desarrollada.

La arquitectura implementada presenta diversas ventajas respecto a un procesamiento tradicional de datos, principalmente debido a la automatización de los procesos de integración y transformación.

Entre los principales beneficios obtenidos destacan:

- Automatización completa del proceso de actualización de información.
- Integración de múltiples fuentes de datos dentro de un único Data Warehouse.
- Escalabilidad gracias al uso de servicios administrados de Google Cloud Platform.
- Actualización periódica de información meteorológica mediante Cloud Scheduler.
- Procesamiento geoespacial utilizando funciones nativas de BigQuery.
- Visualización interactiva mediante Data Studio para apoyar la toma de decisiones.
- Reducción de tareas manuales durante la actualización de los datos.

Estos beneficios permiten disponer de una solución moderna, escalable y preparada para incorporar nuevas fuentes de información en futuras versiones del proyecto.

7.3 Posibles mejoras futuras.

Aunque la solución desarrollada cumple los objetivos definidos para esta entrega, existen diversas oportunidades para ampliar sus capacidades en futuras versiones.

Entre las mejoras identificadas destacan:

- Incorporar información meteorológica de un mayor número de estaciones.
- Utilizar datos meteorológicos históricos para desarrollar modelos predictivos.
- Integrar información proveniente de sensores IoT instalados en terreno.
- Incorporar notificaciones automáticas mediante correo electrónico o mensajería cuando se detecten alertas críticas.
- Desarrollar modelos de Machine Learning para estimar la propagación de incendios forestales.
- Implementar un sistema de priorización automática de evacuación para establecimientos de salud.
- Integrar información de rutas de evacuación y tiempos estimados de traslado.

Estas mejoras permitirán evolucionar la plataforma hacia un sistema de apoyo a la decisión con capacidades predictivas.

8. Conclusiones.

El desarrollo del presente proyecto permitió diseñar e implementar una solución Big Data basada completamente en servicios de Google Cloud Platform para el monitoreo de incendios forestales cercanos a infraestructura crítica de salud rural.

A lo largo de las distintas etapas del proyecto fue posible construir una arquitectura de procesamiento de datos capaz de integrar información proveniente de múltiples fuentes heterogéneas, automatizando tanto los procesos Batch como la ingesta de información en tiempo real. La utilización de Cloud Storage, BigQuery, Cloud Scheduler, Python y Data Studio permitió desarrollar un flujo de procesamiento completamente integrado, eliminando tareas manuales durante la actualización de la información.

Uno de los principales logros obtenidos fue la construcción de un Data Warehouse utilizando un modelo dimensional compuesto por una tabla de hechos de alertas y dimensiones asociadas a incendios, postas rurales, territorio, tiempo y condiciones meteorológicas. Esta estructura facilitó la organización de los datos y permitió realizar consultas analíticas de manera eficiente utilizando las capacidades geoespaciales nativas de BigQuery.

La incorporación de información meteorológica en tiempo real representó una mejora significativa respecto a las entregas anteriores. Mediante la utilización de una API pública y Cloud Scheduler fue posible automatizar consultas periódicas cada cinco minutos, incorporando variables como temperatura, humedad relativa, velocidad y dirección del viento. Estas condiciones fueron integradas al modelo de datos para enriquecer el análisis del riesgo asociado a cada incendio forestal y apoyar la toma de decisiones frente a posibles escenarios de emergencia.

Asimismo, el desarrollo del dashboard en Data Studio permitió sintetizar toda la información procesada en un panel interactivo compuesto por mapas, gráficos estadísticos y tablas dinámicas. Esta herramienta facilita la identificación de regiones con mayor concentración de alertas, el análisis de las condiciones meteorológicas y la localización de postas rurales potencialmente afectadas por incendios forestales, demostrando el potencial de la analítica visual como apoyo a la gestión de emergencias.

Desde el punto de vista técnico, el proyecto permitió aplicar conocimientos relacionados con arquitecturas Big Data, procesamiento Batch y en tiempo real, modelamiento dimensional, consultas geoespaciales, automatización de procesos mediante servicios cloud y desarrollo de soluciones analíticas orientadas a la toma de decisiones. La integración de estas tecnologías permitió construir una plataforma escalable, modular y preparada para incorporar nuevas fuentes de información en futuras implementaciones.

Finalmente, se concluye que los objetivos planteados para el proyecto fueron cumplidos satisfactoriamente. Se logró implementar un flujo de procesamiento automatizado desde la captura de los datos hasta su visualización final, demostrando cómo los servicios de Google Cloud Platform pueden integrarse para desarrollar soluciones orientadas a la prevención y monitoreo de riesgos naturales. La arquitectura propuesta constituye una base sólida para futuros desarrollos, pudiendo evolucionar hacia sistemas predictivos que incorporen

modelos de Machine Learning, nuevas fuentes de datos ambientales y mecanismos automáticos de notificación para organismos responsables de la gestión de emergencias.